

Bancos de Dados de Grafos Distribuídos

Gustavo Estrela de Matos
Instituto de Matemática e Estatísticas
Universidade de São Paulo
São Paulo, Brasil
gestrela@ime.usp.br

Hector Montenegro Terceros
Instituto de Matemática e Estatísticas
Universidade de São Paulo
São Paulo, Brasil
hector@ime.usp.br

Abstract—Vamos fazer este por último...

Index Terms—component, formatting, style, styling, insert Isso aqui eu não entendi direito, não sei como fazer aqui.

I. INTRODUÇÃO

Grafos são objetos matemáticos que podem ser usados como estruturas de dados em diversas aplicações computacionais. Sistemas de Bancos de Dados baseados em grafos são considerados bancos de dados NoSQL [1] e podem ser aplicados em diversos contextos, como o de aplicativos da web; áreas industriais de transportes, telecomunicação e comércio [2]; e também em áreas de pesquisa, como em bioquímica [4], biologia molecular [5] e web semântica [6].

Um grafo pode ser definido como uma dupla $G = (V, E)$, em que V é um conjunto de vértices (ou nós) e E é um conjunto de arcos, que conectam dois nós. Podemos representar um arco $e \in E$, por uma dupla $e = (v_i, v_j)$ com $v_i \in V$ e $v_j \in V$. No contexto de bancos de dados de grafos, usualmente um nó representa uma entidade modelada, e arcos representam relacionamentos entre essas entidades. É comum que os nós recebam rótulos que estão associados ao tipo de entidade modelada, e também um conjunto de propriedades em formato chave-valor, capaz de armazenar atributos da entidade. Além disso, os arcos do modelo também podem receber rótulos que identificam o tipo de relacionamento que é modelado, e um conjunto de propriedades que representam atributos do relacionamento.

Bancos de dados baseados em grafos costumam ser aplicados em contextos em que os dados de interesse possuem relacionamentos complexos ou simplesmente quando boa parte da informação está contida nos relacionamentos. Nestes casos, um banco de dados relacional pode ser inadequado ou ineficiente. Considere, por exemplo, a relação `FABRICA (id_fabricante, id_produto)`. Em uma consulta em que se deseja saber as informações dos produtos fabricados por uma fábrica, no modelo relacional, é necessário fazer uma junção com a relação que armazena os dados dos produtos, enquanto no modelo baseado em grafos, basta percorrer os arcos do relacionamento `FABRICA` que estão ligados ao nó que representa a fábrica de interesse. Além de ser mais eficiente para algumas consultas, sistemas baseados em grafos podem ter consultas mais expressivas, capazes de representar relacionamentos complexos entre os dados [3].

Assim como outros bancos de dados NoSQL, os bancos de dados em grafos são muito utilizados em aplicações que precisam armazenar um grande volume de dados. Para atender a este requisito, alguns bancos de dados baseados em grafos permitem armazenamento distribuído. Este tipo de solução precisa implementar particionamento de dados. Além disso, um sistema distribuído deve providenciar maneiras de responder a consultas que acessam informações de vértices alocados em diferentes máquinas de uma rede.

Neste artigo, nosso principal objetivo é apresentar os conceitos fundamentais e as principais soluções para implementar bancos de dados baseados em grafos distribuídos, e também sistemas para o processamento distribuído de grafos. Ao longo deste trabalho, vamos... informações a serem adicionadas no futuro, com o que vamos colocar de fato no artigo.

II. METODOLOGIA

- Como escolhemos os artigos que lemos para criar esse artigo? - Qual tipo de grafos estamos focados em tratar? (Os que a gente achou... acho que é maioria usado pra rede social??)

III. CONCEITOS FUNDAMENTAIS

Nesta seção apresentamos os conceitos fundamentais para entender o funcionamento de bancos de dados e ferramentas de processamento de dados baseados em grafos, mais especificamente, em contextos distribuídos.

A. Graph DBMS versus Graph Analytics Systems

Para obter os benefícios de um modelo de dados baseado em grafos, é de interesse usar de ferramentas que melhor aproximam esse comportamento. Detalhes adicionais como propriedades, *labels*, direção dos arcos e significados semânticos podem ser usados em modelos mais específicos, como RDF, hipergrafos ou grafos com propriedades. Existem duas categorias de Bancos de Dados de Grafos que são de grande interesse e uso atualmente: *Graph DBMS* e *Graph Analytics Systems*.

Sistemas de Bancos de Dados de Grafos enfatizam armazenamento persistente e garantias transacionais em um ambiente multi-usuário, com esquema flexível e tipicamente com uma linguagem própria de consulta, que permita expressar transações dependentes da estrutura do grafo apropriadamente. A independência lógica e física entre os dados é conquistada

pela adoção de um modelo de alto nível do grafo, por exemplo um grafo com propriedades, aliado a uma separação do armazenamento físico. Esses modelos podem ser classificados como nativos (ou seja, com armazenamento também em formato de grafo) ou não-nativo (usando de outra forma de armazenamento, por exemplo documentos). Exemplos incluem Neo4j, OrientDB, ArangoDB, Gaffer, SAP Hana Graph, e JanusGraph.

Graph Analytics Systems ou *Graph Processing Frameworks* focam-se principalmente em tarefas analíticas sobre grandes grafos, com tolerância a falhas e processamento distribuído. Essas tarefas podem demorar horas e ser realizadas sobre um largo *cluster*, como por exemplo um algoritmo de *PageRank* ou centralidade. São adotados processamentos assíncronos e distribuídos, e se busca reduzir o I/O do cluster, no qual assume-se que não haja recursos compartilhados e qualquer transmissão de dados ou informações gerará um custo. Exemplos desse tipo de ferramenta incluem Pregel, Blogel, Apache Giraph e Gradoop.

A principal diferença entre essas duas classes de ferramentas é no tipo de transação a que dão mais importância e, por outro lado, onde perdas são mais aceitáveis. GDBMS focam-se na garantia de transações de *update*, afetando tipicamente apenas uma porção pequena do grafo, e pagam o custo em tempo e eficiência para essa garantia. GAS, por outro lado, focam-se em tarefas de processamento do grafo inteiro, tipicamente em ambientes distribuídos, adotando perdas de qualidade próximas a outras ferramentas NoSQL.

Uma pesquisa recente entre pesquisadores e usuários dessas ferramentas [15] aponta várias questões interessantes sobre seu uso. Primeiramente, muitos usuários reportam grafos muito grandes, da ordem de milhões de nós e bilhões de arcos, mesmo em organizações de tamanho médio. Entre pesquisadores há bastante espaço para o uso de GAS, enquanto que para outros usuários (por exemplo, na indústria e outras aplicações) é muito mais comum a preferência por GDBMS, enquanto que GAS não são muito aplicados. Além disso, entre usuários da indústria é notável a modelagem como grafos de entidades tradicionalmente usadas em RDBMS, como a tríade *produto-pedido-transação*. Isso aponta para o valor de análises realizadas primariamente nas conexões entre tais entidades, possivelmente complementar às análises relacionais

B. Cortes de grafos

O conceito de corte em grafo é importante para formalização e análise do particionamento de um grafo em um contexto distribuído. Para se trabalhar com grafos de maneira distribuída, é necessário criar um particionamento do grafo, para que cada parte seja alocada em um nó da rede de computadores usada. Um particionamento precisa ser feito de maneira que o processamento do grafo seja balanceado, ou seja, as máquinas devem ter números de acessos similares; além disso, é importante fazer com que os processamentos do grafo sejam feitos com o menor número de nós de computação possível, pois o processamento que envolve mais de um nó de computação necessita de maior comunicação pela rede,




Fig. 1. Grafo com exemplo de corte. O corte apresentado é definido pelos conjuntos de vértices E, C , em azul, e A, B, D , em branco. Os arcos de cor vermelha são os arcos deste corte. No total, são 4 arcos vermelhos neste corte, ou seja, o tamanho deste corte é 4.

aumentando a latência da operação. Para analisar estes dois aspectos com maior formalismo, definimos o conceito de corte.

Um corte é um particionamento em dois conjuntos disjuntos de vértices de um grafo. Seja $G = (V, E)$ um grafo, então um conjunto $S \subseteq V$ de vértices induz o corte $(S, V \setminus S)$. Um arco $e \in E$ é chamada de arco do corte se ele atravessa as partes, ou seja, se $e = (u, v)$ com $u \in S$ e $v \notin S$, ou $u \notin S$ e $v \in S$. Chamamos de tamanho do corte o número de arcos que são arcos do corte. A figura 1 apresenta um exemplo de corte em um grafo.

Note que qualquer particionamento (não apenas bipartições) do conjunto de vértices de um grafo pode ser realizado após recursivas aplicações de cortes. Portanto, é possível construir e analisar cortes olhando apenas para bipartições do grafo original. Perceba também que ao fazer um particionamento, podemos analisar o balanceamento de processamento dos nós de computação de acordo com o número de partes (e vértices) que são alocadas aos nós de computação. Além disso, é possível analisar a quantidade de comunicação entre nós de acordo com a quantidade de arcos que conectam diferentes partes, que podem estar alocadas em dois nós de computação diferentes.

Se formos falar de cortes baseados em arcos, é melhor adicionar mais um pedaço de texto explicando esse tipo de corte.

IV. PARTICIONAMENTO DE GRAFOS

O particionamento de um grafo é o processo que permite dividir um grafo em diferentes partes, que podem ser alocadas em diferentes máquinas, permitindo o processamento e armazenamento distribuído do grafo. Nesta seção, apresentaremos três diferentes abordagens de particionamento. A

primeira, baseada no algoritmo METIS [7], é uma heurística que tenta minimizar a quantidade de arcos que conectam partes diferentes; a segunda faz um particionamento aleatório; e a terceira particiona os vértices de acordo com o valor de alguns atributos destes vértices.

A. Particionamento com cortes mínimos

O algoritmo METIS tem como objetivo produzir um particionamento com k partes que minimiza a quantidade de arcos atravessando partes, ou seja, produz cortes mínimos no grafo. O problema de encontrar tal partição é chamado k -particionamento de um grafo, e vamos defini-lo assim: dado um grafo $G = (V, E)$, com $|V| = n$, particione V em k conjuntos V_1, V_2, \dots, V_k de maneira que $V_i \cap V_j = \emptyset$ para $i \neq j$, $\bigcup_{i=1}^k V_i = V$, e $|V_i| = n/k$ para $i \in \{1, \dots, k\}$ (sem perda de generalidade, se n não é divisível por k , então adicione nós "fantasmas" até que $k|n$). O k -particionamento também pode ser generalizado ao considerar pesos para arcos, adicionando uma informação de importância ou relevância para as conexões, mas por facilidade vamos considerar apenas o caso em que todos os pesos dos arcos são iguais, o que é consistente com a definição que apresentamos. Lembre também que um corte em um grafo também é uma bipartição do grafo; a escolha por um dos nomes ao longo desta seção será feita de maneira conveniente à explicação dos conceitos.

O k -particionamento possui importância em aplicações de computação paralela e distribuída, e foi provado ser NP-completo [8], ou seja, o problema se torna intratável rapidamente com o aumento da instância. Por isso, o algoritmo METIS é uma heurística, ou seja, a solução produzida não é ótima em geral.

A heurística METIS resolve o problema do k -particionamento realizando aplicações recursivas de um procedimento de biparticionamento. O número total de chamadas recursivas feitas é no máximo $\lceil \log x \rceil$. O algoritmo de bipartição é também uma heurística que tenta achar o corte de menor custo no grafo. Como achar esta partição no grafo pode tomar muito tempo, uma etapa de encolhimento é feita antes, e depois disso o grafo bipartido é expandido e refinado até se obter uma bipartição do grafo original. O algoritmo de biparticionamento é composto por três etapas:

- encolhimento: pares de vértices são escolhidos dois a dois, e são acoplados em um vértice novo que reúne todos os arcos que estavam nos vértices antigos. Esta etapa é repetida até o grafo ser considerado pequeno;
- biparticionamento: uma heurística (novamente) determina um corte com tamanho pequeno;
- expansão: os vértices acoplados são desfeitos ao mesmo tempo que a bipartição é atualizada de acordo com os novos nós.

Durante o encolhimento, os vértices devem ser escolhidos dois a dois sem repetições, o que é equivalente a escolher um emparelhamento do grafo. Um emparelhamento é um conjunto de arcos de um grafo que não tem vértices em comum. O algoritmo METIS implementa uma heurística de emparelhamento máximo (com maior número de arcos), para escolher os pares

de vértices para serem acoplados. A vantagem de fazer um emparelhamento máximo durante o encolhimento é diminuir o número de iterações até que o grafo fique pequeno. Segundo Karypis et al., um grafo de tamanho 100 é pequeno o suficiente para seguir para etapa de bipartição.

Com o grafo encolhido, uma bipartição deve ser mais facilmente encontrada. Porém, como este problema ainda é NP-difícil [8], uma outra heurística é usada. Esta heurística constrói um corte do grafo, e é um algoritmo guloso que começa com um corte que contém apenas um vértice, escolhido aleatoriamente, e a cada iteração aumenta o conjunto de vértices do corte ao adicionar um novo vértice, até que o corte tenha metade dos vértices do grafo. Em cada etapa do algoritmo, um vértice de fora do corte que está conectado a um arco do corte é escolhido. Esta escolha é feita de acordo com o ganho de arcos de corte que o novo vértice pode adicionar (ou remover) no corte atual. Seja S_i o conjunto de vértices do corte da i -ésima iteração, então, definimos o ganho de adicionar um vértice como:

$$g_v = |\{u \mid (v, u) \in E, u \notin S_i\}| - |\{u \mid (v, u) \in E, u \in S_i\}| \quad (1)$$

A medida g_v também é útil para a última etapa do biparticionamento, que ao mesmo tempo que expande o grafo colapsado, faz um refinamento do biparticionamento produzido. A cada iteração desta etapa, um nó é desacoplado e então todos os vértices da borda do corte do biparticionamento são analisados para uma possível troca de partes. Na prática, esta etapa é aplicada com otimizações que tornam desnecessário analisar todos os vértices da borda por várias iterações, tornando essa heurística mais eficiente.

O algoritmo METIS é até hoje um dos principais algoritmos de particionamento de grafos, e por isso é usado como base de comparação para outras propostas [9].

B. Particionamentos aleatórios e por intervalos

Um particionamento aleatório atribui partes aos vértices de maneira aleatória e uniforme. Esta atribuição é feita de acordo com alguma função de hash, que pode ser aplicada, por exemplo, no atributo de identificação do vértice. Este tipo de particionamento é facilmente implementado visto que o único requisito é que uma função de hash distribua os vértices de maneira equilibrada entre os nós.

Um particionamento por intervalo é similar, e também precisa de uma função de hash, mas ao invés de atribuir partes a valores de um atributo, essa função atribui partes a intervalos dos valores de atributos. Esta abordagem é útil quando há um atributo nos vértices que determina a chance de relacionamento entre vértices de acordo com seus valores; por exemplo, se os vértices são pessoas com um atributo de latitude e longitude, então é razoável admitir que os relacionamentos (arcos) ocorrerão mais entre pessoas que tem valores próximos para esses atributos.

Além de ser facilmente implementada, essas estratégias precisam de pouco processamento e pouco espaço de memória

TABLE I
CARACTERÍSTICAS DE ABORDAGENS DE PARTICIONAMENTO

	Particionamento de corte mínimo	Particionamento aleatório e por intervalo
Usa estrutura do grafo	Sim	Não
Dificuldade de cálculo do particionamento	Difícil	Fácil
Necessita de armazenar partes explicitamente	Sim	Não
Atribuição de parte para um novo vértice	Depende de criação de política	Automática

para identificar a qual parte um vértice foi alocado. Outra vantagem desses métodos é que um novo vértice do grafo pode ser atribuído para uma parte de maneira rápida, diferente da abordagem de cortes mínimos.

C. Comparação entre abordagens de particionamento

Ambas abordagens apresentadas anteriormete podem ser aplicadas vantajosamente. A estratégia baseada em cortes se aproveita da estrutura da estrutura do problema de interesse e pode produzir um particionamento que possui poucos arcos conectando duas partes, ou seja, um particionamento que agrupa as entidades que se relacionam constantemente e, portanto, faz as consultas precisarem de menos comunicações entre nós de computação. No caso dos particionamentos aleatórios ou por intervalos, o processo de particionamento é simples de se implementar e necessita de pouco espaço de armazenamento. Além disso, particionamentos aleatórios podem atribuir partes a novos vértices assim que eles são criados.

Por outro lado, ambas abordagens também possuem desvantagens. A principal desvantagem do particionamento por cortes é a sua complexidade, de implementação e de recuperação das partes. Além disso, no particionamento baseado em cortes, uma política precisa ser definida para quando um novo vértice é criado: este vértice precisa ser eventualmente colocado em alguma parte, mas deve ser considerado que refazer todo processo de particionamento sempre que um novo nó é criado é inviável. A desvantagem do método particionamento aleatório e não usar a estrutura dos dados do problema, o que pode fazer com que operações comuns causem um grande tráfego na rede, pois os nós fortemente relacionados não estarão disponíveis nos mesmos locais.

O trabalho de Khayyat et al. mostra que, de fato, não um consenso de qual é a melhor alternativa de particionamento [10]. Portanto, a escolha de uma estratégia de particionamento depende da aplicação. A tabela I apresenta os principais aspectos estratégias de particionamento que apresentamos nesta seção.

V. SISTEMAS GERENCIADORES DE BANCOS DE DADOS EM GRAFOS

Os Sistemas Gerenciadores de Bancos de Dados em Grafos, a seguir referenciados como SGBDG, são as ferramentas que focam-se em manter todas as garantias de um SGBDR, mas usando de uma representação de dados voltada a Grafos ao invés de Relações. Portanto, essas ferramentas são focadas em tarefas OLTP, com acesso de baixa latência a pequenas partes do grafo, e trazem vantagens como garantia de persistência e otimização de *queries*. Muitos sistemas desse tipo são centralizados, como por exemplo Neo4j [19] e OrientDB [?], que entretanto oferecem replicação como uma solução para fornecer alta disponibilidade para consultas de leitura, mas já estamos vendo o surgimento e popularização de sistemas distribuídos, como JanusGraph [20], Horton+ [16] e ThingSpan [17]. Esses últimos são tipicamente construídos sobre um *backend* distribuído, como Apache Hadoop ou Cassandra, visando a construção de um sistema em que os servidores do *cluster* não compartilham nenhum recurso, e o sistema então se ocupa da tarefa de comunicação interna.

Todas essas ferramentas implementam alguma forma de consulta aos dados. Várias possuem sua própria linguagem de consulta declarativa, como a Cypher do Neo4j, uma linguagem de checagem sobre todo o grafo, como a Gremlin da Apache TinkerPop usada no JanusGraph e OrientDB, ou mesmo uma extensão da SQL que permita a expressão de transversais no grafo, como está disponível no OrientDB. Também é muito comum que sejam disponibilizadas APIs para processamento de transações e processamento de tarefas. A maioria dessas linguagens não possui interpretação semântica nativa, a exceção sendo SPARQL, uma linguagem montada para a consulta de bancos de dados de RDF, que por vezes é disponibilizada nas ferramentas aqui apresentadas.

Um tipo de ferramenta que possui muitas características similares a SGBDG, incluindo conexões diretas entre itens de dados e uma linguagem própria de consulta, são os bancos de dados de RDF (*Resource Description Framework*), com a linguagem SPARQL. Cada item de RDF é uma relação entre duas entidades também presentes no BD, então a tradução dessa relação como um arco entre nós representantes das entidades é natural, o que aproxima tais tipos de ferramentas. Inclusive, muitas ferramentas de SGBDG permitem que um usuário traduza uma consulta SPARQL em uma na linguagem própria da ferramenta, potencializando o conhecimento acumulado em SPARQL e a expressividade semântica dessa linguagem. Entretanto, essas ferramentas estão fora do escopo do presente trabalho.

A. Neo4j

Neo4j é o SGBDG mais popular atualmente, de acordo com o ranking DB-Engines [?]. É um SGBDG nativo, centralizado, com uma versão *open-source* (*Community*) e uma restrita (*Enterprise*). Na versão *open-source*, são disponíveis a linguagem de consulta Cypher e APIs para várias linguagens de programação (.Net, Java, JavaScript, Go, e Python), além das garantias de transação similares a ACID. Na versão paga,

há extensões como a implementação em um *cluster*, com replicação completa do grafo para agilizar transações de consulta simultâneas, mas sem *sharding* ou particionamento do grafo original. Também são oferecidas nessa versão ferramentas de *backup online* e gerenciamento de acessos. Uma visão geral dessa ferramenta está na figura 2. O Neo4j usa do *Property Graph Model*, um grafo direcionado e onde se representam os nós, arcos e propriedades de nós ou arcos, que são guardadas em três arquivos separados

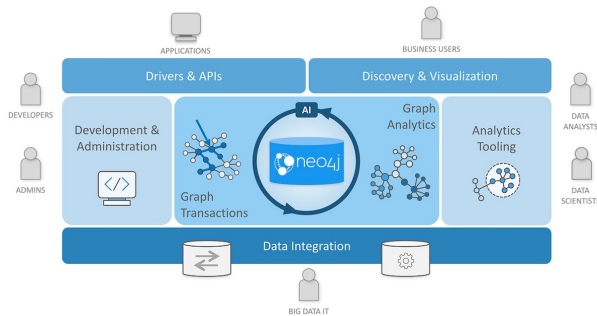


Fig. 2. Ilustração das capacidades do Neo4j, especialmente sua integração com vários tipos de usuários e suas ferramentas.

A linguagem Cypher é declarativa, inspirada no SQL e estendida visando a expressão de estruturas do grafo a serem procuradas. Essa linguagem se baseia numa sintaxe com as cláusulas *START-SELECT-WHERE-RETURN*. *START*, opcional, declara um nó específico de onde iniciar a transversal. *SELECT* define o padrão a ser buscado, tipicamente em nós e as relações entre eles. *WHERE* permite a filtragem a partir de propriedades e outras comparações. *RETURN* aponta que informações devem ser retornadas, inclusive permitindo funções de agregação.

Rudimentos de *ASCII-art* são usados na expressão de padrões a ser buscados pela cláusula *SELECT*, com nós do grafo representados por parênteses () e arcos representados por dois traços --, possivelmente com uma direção especificada -- > ou < --. Essas estruturas podem ser melhor especificadas usando de tipos e *labels* para relações e nós respectivamente, e de propriedades dessas entidades. O otimizador de query sabe usar dessas especificações para limitar o escopo das transversais sobre o grafo, agilizando as consultas apropriadamente. Cada entidade da expressão pode receber uma variável local, que é então usada nas cláusulas *WHERE* e *RETURN* para o tratamento dos dados retornados.

No exemplo da figura 3, a query busca um nó de label Pessoa, com uma propriedade "name" tendo valor "Jennifer", que tenha uma relação de tipo WORKS_FOR com um nó de label "Company". Desse último nó, ela retorna a propriedade "name".

```
MATCH (:Person {name: 'Jennifer'})-[:WORKS_FOR]->(company:Company)
RETURN company.name
```

Fig. 3. Exemplo de query em Cypher

B. OrientDB

OrientDB é um SGBD que suporta modelos de documentos, grafos, chave-valor e objetos, com o principal atrativo sendo a capacidade de trabalhar mais de um desses formatos no mesmo gerenciador, criando uma base de dados multi-modelo. Os dados são armazenados como documentos de chave-valor, em que cada valor pode ser um dado primitivo, documentos internos ou listas de outros documentos, e são agrupados em "classes". De nosso principal interesse é a forma como o SGBDG implementa *links* entre esses documentos, que são processados sempre que um documento é processado, de forma a agilizar as transversais que são de interesse em grafos.

Usado como grafo, cada nó do grafo é armazenado como um registro com um ID próprio e as listas de arcos incidentes (entrando ou saindo), e cada arco também é armazenado com um ID próprio, seus nós de saída e chegada (chamados cabeça e cauda), e um *label* para o tipo de relacionamento entre os vértices. Ambas as entidades, como documentos sem esquema restrito, podem receber qualquer quantidade de propriedades a mais como campos chave-valor. Como todo registro no SGBD possui um ID próprio, o acesso a tais registros é rápido e direto, evitando o processamento de longas listas.

Evitando criar uma nova linguagem de consulta, OrientDB implementa o SQL estendido para funcionalidades de grafos, mantendo a sintaxe *SELECT-FROM-WHERE-GROUP BY* e encapsulamento de consultas, mas perdendo a cláusula *HAVING*. A navegação pelas relações entre os registros do BD é feita através dos links presentes nos registros, e referenciada por *dot notation*. Por exemplo, assumindo que registros da classe *Employee* possuam uma propriedade *city* com um link para registros dessa classe, realizar uma consulta para extrair apenas empregados de uma dada cidade é fácil como mostrado na figura ???. Também é possível aplicar funções sobre valores retornados (por exemplo, *sum* para uma agregação), ou usar de métodos nos próprios pares chave-valor, como na figura ???.

```
SELECT * FROM Employee WHERE city.name = 'Rome'
```

Fig. 4. Empregados na cidade de 'Rome', no OrientDB SQL.

```
SELECT name.append(' ').append(surname) FROM Employee
```

Fig. 5. Retornando um campo que concatene o primeiro e último nome de cada empregado, no OrientDB SQL.

[18] [16] [17]

VI. GRAPH ANALYTICS SYSTEMS

Com o crescimento das aplicações na internet e em outras áreas como transportes e comércio, a demanda por processamento eficiente e distribuído de grafos cresceu. Outros arcabouços de processamento distribuído com propósitos mais genéricos, como MapReduce, podem não ser adequados a alguns problemas de grafos. Por isso, tornou-se necessário a criação de arcabouços de processamento distribuído especializados em grafos, que permitem escrever programas

que fazem cálculos sobre grafos de maneira mais intuitiva e eficiente. Chamamos estes arcabouços de *Graph Analytics Systems* (GASs).

Uma das primeiras soluções GAS foi o sistema Pregel, criado por engenheiros do Google [11]. Pregel possui uma abordagem de processamento centrada nos vértices do grafo. Os programas deste arcabouço funcionam em rodadas chamadas de *supersteps*; a cada *superstep* um vértice pode receber uma mensagem, fazer uma computação, enviar uma mensagem, ou decidir parar. Um programa acaba quando todos os vértices decidem parar. Este método de computação também é a base para outros GAS, como o Giraph [12], Surfer [13], GoldenOrb [14] e Mizan [10]. Estas variações do sistema Pregel normalmente se diferenciam pelo sistema de armazenamento utilizado e também pelo tipo de particionamento de grafo utilizado.

O sistema Pregel e suas variantes podem ainda não ser adequados para algumas aplicações, principalmente aquelas em que são construídos grafos densos. Em um grafo denso, a quantidade de arcos pode ser muito grande, criando um alto tráfego de informação localmente e também entre os nós de computação. Como solução para este problema o sistema Blogel foi desenvolvido. Este sistema utiliza o mesmo método de processamento que o Pregel, porém faz cálculos centrados em blocos de vértices, evitando comunicação excessiva entre vértices.

A. *Pregel*

B. *Blogel*

REFERENCES

- [1] “NoSQL Databases”, <http://nosql-database.org/>.
- [2] “Neo4j Customers”, <https://neo4j.com/customers/>.
- [3] M. Hunger, R. Boyd. “RDBMS & Graphs: SQL vs. Cypher Query Languages” Neo4j Blog. Mar. 2016. <https://neo4j.com/blog/sql-vs-cypher-query-languages/>
- [4] N. Swainston et al., “biochem4j: Integrated and extensible biochemical knowledge through graph databases”, PLOS ONE, vol. 12, no. 7, p. e0179130, Jul. 2017.
- [5] F. Olken, “Graph Data Management for Molecular Biology”, OMICS: A Journal of Integrative Biology, vol. 7, no. 1, pp. 75–78, Jan. 2003.
- [6] B. McBride, “Jena: a semantic Web toolkit,” IEEE Internet Computing, vol. 6, no. 6, pp. 55–59, Nov. 2002.
- [7] Karypis, G., & Kumar, V. (1998). “A Fast and High Quality Multilevel Scheme for Partitioning Irregular Graphs”. SIAM Journal on Scientific Computing, 20(1), 359–392. <https://doi.org/10.1137/s1064827595287997>
- [8] Andreev, K., & Racke, H. (2006). “Balanced Graph Partitioning”. Theory of Computing Systems, 39(6), 929–939. <https://doi.org/10.1007/s00224-006-1350-7>
- [9] D. Avdiukhin, S. Pupyrev, e G. Yaroslavtsev, “Multi-dimensional balanced graph partitioning via projected gradient descent”, Proceedings of the VLDB Endowment, vol. 12, n° 8, p. 906–919, abr. 2019.
- [10] Z. Khayyat, K. Awara, A. Alonazi, H. Jamjoom, D. Williams, e P. Kalnis, “Mizan”, in Proceedings of the 8th ACM European Conference on Computer Systems - EuroSys ’13, 2013.
- [11] G. Malewicz et al., “Pregel”, in Proceedings of the 2010 international conference on Management of data - SIGMOD ’10, 2010.
- [12] Avery, Ching. “Giraph: Large-scale graph processing infrastructure on hadoop.” Proceedings of the Hadoop Summit. Santa Clara 11.3 (2011): 5-9.
- [13] Chen, Rishan, et al. “Improving large graph processing on partitioned graphs in the cloud.” Proceedings of the Third ACM Symposium on Cloud Computing. ACM, 2012.
- [14] GoldenOrb. A Cloud-based Open Source Project for MassiveScale Graph Analysis. <http://goldenorbos.org/>, 2012
- [15] Sahu, Siddhartha et al. “The Ubiquity of Large Graphs and Surprising Challenges of Graph Processing: Extended Survey” The VLDB Journal (2019): n. pag. Crossref. Web.
- [16] M. Sarwat, S. Elnikety, Y. He, and M. F. Mokbel, “Horton+: A Distributed System for Processing Declarative Reachability Queries over Partitioned Graphs”, PVLDB, vol. 6, no. 14, pp. 1918–1929, 2013.
- [17] “ThingSpan” [Online]. Available: <http://www.objectivity.com/products/thingspan/>.
- [18] **preciso pegar essa referencia certinha** M. Nolé, C. Sartiani, “Graph Management Systems: A Survey”
- [19] **preciso pegar essa referencia certinha**
- [20] **preciso pegar essa referencia certinha**